Analisi e previsione salario mensile

Claudio Raffaele Salerno

2025/2026

Contents

1 ABSTRACT **2**

2 Introduzione **2**

2.1 Descrizione delle variabili 2

3 EDA **3**

3.1 Trasformazione delle variabili 3

3.2 Statistiche descrittive 4

3.3 Tabelle di contingenza 5

3.4 Analisi di correlazione 6

3.5 Grafici 8

3.6 Fit delle distribuzioni univariate 17

4 Costruzione del modello **19**

4.1 Suddivisione del dataset in training set e test set 19

4.2 Regressione gaussiana con `lwage` 19

4.3 Regressione Gamma 22

4.4 Interpretazione dei coefficienti 28

4.5 Previsioni 29

4.6 Effetti marginali 31

5 Conclusioni **39**

1 ABSTRACT

Il presente studio ha l'obiettivo di analizzare e prevedere il salario mensile degli individui attraverso l'utilizzo dei Modelli Lineari Generalizzati, studiando l'influenza esercitata da diverse variabili esplicative sul livello retributivo osservato.

L'analisi si basa sul dataset WAGE2, disponibile sulla piattaforma Kaggle, che raccoglie informazioni relative a caratteristiche individuali, formative e lavorative, come vedremo di seguito.

L'obiettivo principale è comprendere quali variabili risultano maggiormente associate al salario e valutare se tutte le informazioni presenti nel dataset contribuiscano in modo significativo alla spiegazione della variabile risposta.

2 Introduzione

```
## # A tibble: 6 x 17
##   `769`  `40`  `93`  `35`  `12`  `11` `2...7`  `31` `1...9` `0...10` `0...11`
##   <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>   <dbl> <dbl>   <dbl>    <dbl>    <dbl>
## 1   808    50   119    41    18    11      16    37       1        0        0
## 2   825    40   108    46    14    11       9    33       1        0        0
## 3   650    40    96    32    12    13       7    32       1        0        0
## 4   562    40    74    27    11    14       5    34       1        0        0
## 5  1400    40   116    43    16    14       2    35       1        1        0
## 6   600    40    91    24    10    13       0    30       0        0        0
## # i 6 more variables: `1...12` <dbl>, `1...13` <dbl>, `2...14` <chr>,
## #   `8...15` <chr>, `8...16` <chr>, `6.6450909999999999` <dbl>
```

```
##  [1] "769"                "40"                 "93"
##  [4] "35"                 "12"                 "11"
##  [7] "2...7"              "31"                 "1...9"
## [10] "0...10"             "0...11"             "1...12"
## [13] "1...13"             "2...14"             "8...15"
## [16] "8...16"             "6.6450909999999999"
```

```
## # A tibble: 6 x 17
##    wage hours    IQ   KWW  educ exper tenure   age married black south urban
##   <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>  <dbl> <dbl>   <dbl> <dbl> <dbl> <dbl>
## 1   808    50   119    41    18    11     16    37       1     0     0     1
## 2   825    40   108    46    14    11      9    33       1     0     0     1
## 3   650    40    96    32    12    13      7    32       1     0     0     1
## 4   562    40    74    27    11    14      5    34       1     0     0     1
## 5  1400    40   116    43    16    14      2    35       1     1     0     1
## 6   600    40    91    24    10    13      0    30       0     0     0     1
## # i 5 more variables: sibs <dbl>, brthord <chr>, meduc <chr>, feduc <chr>,
## #   lwage <dbl>
```

2.1 Descrizione delle variabili

Il dataset utilizzato per l'analisi contiene 934 osservazioni e 17 variabili. Le informazioni disponibili riguardano caratteristiche individuali, formative, lavorative e familiari degli individui osservati. Di seguito vengono presentate le variabili considerate:

- `wage`: salario mensile;
- `hours`: ore medie lavorate settimanalmente;
- `IQ`: punteggio del quoziente intellettivo;
- `KWW`: punteggio relativo alla conoscenza del mondo del lavoro;
- `educ`: anni di istruzione;
- `exper`: anni di esperienza lavorativa;
- `tenure`: anni trascorsi presso l'attuale datore di lavoro;
- `age`: età dell'individuo;
- `married`: variabile binaria pari a 1 se l'individuo è sposato;
- `black`: variabile binaria pari a 1 se l'individuo è nero;
- `south`: variabile binaria pari a 1 se l'individuo vive nel Sud;
- `urban`: variabile binaria pari a 1 se l'individuo vive in un'area urbana;
- `sibs`: numero di fratelli e sorelle;
- `brthord`: ordine di nascita;
- `meduc`: anni di istruzione della madre;
- `feduc`: anni di istruzione del padre;
- `lwage`: logaritmo naturale del salario.

Le variabili `brthord`, `meduc` e `feduc` presentano alcuni valori mancanti, indicati come `NA`. In una prima fase tali variabili vengono mantenute, così da poter osservare la struttura generale del dataset durante l'analisi esplorativa. Successivamente, nella fase di costruzione del modello, esse saranno escluse per evitare problemi legati alla presenza di osservazioni incomplete.

3 EDA

L'analisi esplorativa consente di osservare la struttura del dataset, valutare la distribuzione delle principali variabili e individuare eventuali relazioni preliminari tra salario e caratteristiche individuali.

Iniziamo con un riepilogo dei dati, così da ottenere una comprensione generale della loro struttura, osservando le principali statistiche descrittive delle variabili considerate.

3.1 Trasformazione delle variabili

```
## tibble [934 x 17] (S3: tbl_df/tbl/data.frame)
##  $ wage   : num [1:934] 808 825 650 562 1400 ...
##  $ hours  : num [1:934] 50 40 40 40 40 40 40 45 40 43 ...
##  $ IQ     : num [1:934] 119 108 96 74 116 91 114 111 95 132 ...
##  $ KWW    : num [1:934] 41 46 32 27 43 24 50 37 44 44 ...
##  $ educ   : num [1:934] 18 14 12 11 16 10 18 15 12 18 ...
##  $ exper  : num [1:934] 11 11 13 14 14 13 8 13 16 8 ...
##  $ tenure : num [1:934] 16 9 7 5 2 0 14 1 16 13 ...
##  $ age    : num [1:934] 37 33 32 34 35 30 38 36 36 38 ...
##  $ married: Factor w/ 2 levels "0","1": 2 2 2 2 2 1 2 2 2 2 ...
##  $ black  : Factor w/ 2 levels "0","1": 1 1 1 1 2 1 1 1 1 1 ...
##  $ south  : Factor w/ 2 levels "0","1": 1 1 1 1 1 1 1 1 1 1 ...
##  $ urban  : Factor w/ 2 levels "0","1": 2 2 2 2 2 2 2 1 2 1 ...
##  $ sibs   : num [1:934] 1 1 4 10 1 1 2 2 1 1 ...
##  $ brthord: chr [1:934] "." "2" "3" "6" ...
##  $ meduc  : chr [1:934] "14" "14" "12" "6" ...
##  $ feduc  : chr [1:934] "14" "14" "12" "11" ...
##  $ lwage  : num [1:934] 6.69 6.72 6.48 6.33 7.24 ...
```

```
## # A tibble: 6 x 17
##    wage hours    IQ   KWW  educ exper tenure   age married black south urban
##   <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>  <dbl> <dbl> <fct>   <fct> <fct> <fct>
## 1   808    50   119    41    18    11     16    37 1       0     0     1
## 2   825    40   108    46    14    11      9    33 1       0     0     1
## 3   650    40    96    32    12    13      7    32 1       0     0     1
## 4   562    40    74    27    11    14      5    34 1       0     0     1
## 5  1400    40   116    43    16    14      2    35 1       1     0     1
## 6   600    40    91    24    10    13      0    30 0       0     0     1
## # i 5 more variables: sibs <dbl>, brthord <chr>, meduc <chr>, feduc <chr>,
## #   lwage <dbl>
```

```
##       wage            hours             IQ             KWW
##  Min.   : 115.0   Min.   :20.00   Min.   : 50.0   Min.   :12.00
##  1st Qu.: 668.5   1st Qu.:40.00   1st Qu.: 92.0   1st Qu.:31.00
##  Median : 905.5   Median :40.00   Median :102.0   Median :37.00
##  Mean   : 958.1   Mean   :43.93   Mean   :101.3   Mean   :35.75
##  3rd Qu.:1160.0   3rd Qu.:48.00   3rd Qu.:112.0   3rd Qu.:41.00
##  Max.   :3078.0   Max.   :80.00   Max.   :145.0   Max.   :56.00
##       educ            exper           tenure           age        married
##  Min.   : 9.00   Min.   : 1.00   Min.   : 0.00   Min.   :28.00   0:100
##  1st Qu.:12.00   1st Qu.: 8.00   1st Qu.: 3.00   1st Qu.:30.00   1:834
##  Median :12.00   Median :11.00   Median : 7.00   Median :33.00
##  Mean   :13.47   Mean   :11.56   Mean   : 7.24   Mean   :33.08
##  3rd Qu.:16.00   3rd Qu.:15.00   3rd Qu.:11.00   3rd Qu.:36.00
##  Max.   :18.00   Max.   :23.00   Max.   :22.00   Max.   :38.00
##  black   south   urban        sibs          brthord             meduc
##  0:814   0:615   0:264   Min.   : 0.000   Length:934         Length:934
##  1:120   1:319   1:670   1st Qu.: 1.000   Class :character   Class :character
##                          Median : 2.000   Mode  :character   Mode  :character
##                          Mean   : 2.943
##                          3rd Qu.: 4.000
##                          Max.   :14.000
##     feduc              lwage
##  Length:934         Min.   :4.745
##  Class :character   1st Qu.:6.505
##  Mode  :character   Median :6.808
##                     Mean   :6.779
##                     3rd Qu.:7.056
##                     Max.   :8.032
```

Le variabili `married`, `black`, `south` e `urban` vengono trasformate in fattori, poiché rappresentano variabili qualitative binarie. Questa trasformazione consente di gestirle correttamente sia nella fase grafica sia nella successiva fase di modellizzazione.

3.2 Statistiche descrittive

Il riepilogo statistico mostra alcune caratteristiche rilevanti del dataset. La variabile `wage`, che rappresenta il salario mensile, assume valori compresi tra 115 e 3078, con una media pari a circa 958 e una mediana pari a 905.5. La differenza tra media e mediana, insieme alla presenza di un valore massimo piuttosto elevato, suggerisce una possibile asimmetria positiva nella distribuzione dei salari.

Per quanto riguarda le ore lavorate settimanalmente, la variabile `hours` presenta una media pari a circa 43.93 ore, con mediana pari a 40. Questo indica che la maggior parte degli individui lavora intorno alle 40 ore settimanali, anche se sono presenti soggetti che lavorano fino a 80 ore.

Le variabili legate al capitale umano mostrano valori abbastanza coerenti: il punteggio medio di `IQ` è pari a circa 101.3, mentre gli anni medi di istruzione sono pari a 13.47. L'esperienza lavorativa media è pari a circa 11.56 anni, mentre la permanenza media presso l'attuale datore di lavoro è pari a 7.24 anni.

Dal punto di vista delle variabili qualitative, si osserva che la maggior parte degli individui risulta sposata, poiché la variabile `married` assume valore 1 in 834 casi e valore 0 in 100 casi. Inoltre, la maggioranza degli individui vive in area urbana, dato che `urban` assume valore 1 in 670 casi. La variabile `south` mostra invece che 319 individui vivono nel Sud, mentre 615 non vi risiedono.

Infine, le variabili `brthord`, `meduc` e `feduc` risultano lette come variabili di tipo character, a causa della presenza di valori mancanti. Per questo motivo, pur essendo osservate in fase esplorativa, saranno successivamente escluse dalla costruzione del modello.

3.3 Tabelle di contingenza

Per approfondire la distribuzione congiunta di alcune variabili qualitative, vengono costruite alcune tabelle di contingenza. In particolare, si osserva la relazione tra lo stato civile degli individui e due caratteristiche territoriali: la residenza in area urbana e la residenza nel Sud.

```
##
##            0        1
##   0 23.00000 77.00000
##   1 28.89688 71.10312
```

La prima tabella mette in relazione lo stato civile con la variabile `urban`, che indica se l'individuo vive in un'area urbana. Tra gli individui non sposati, il 23% vive in aree non urbane, mentre il 77% vive in città. Per quanto riguarda gli individui sposati, il 28,90% vive in aree non urbane e il 71,10% vive in città.

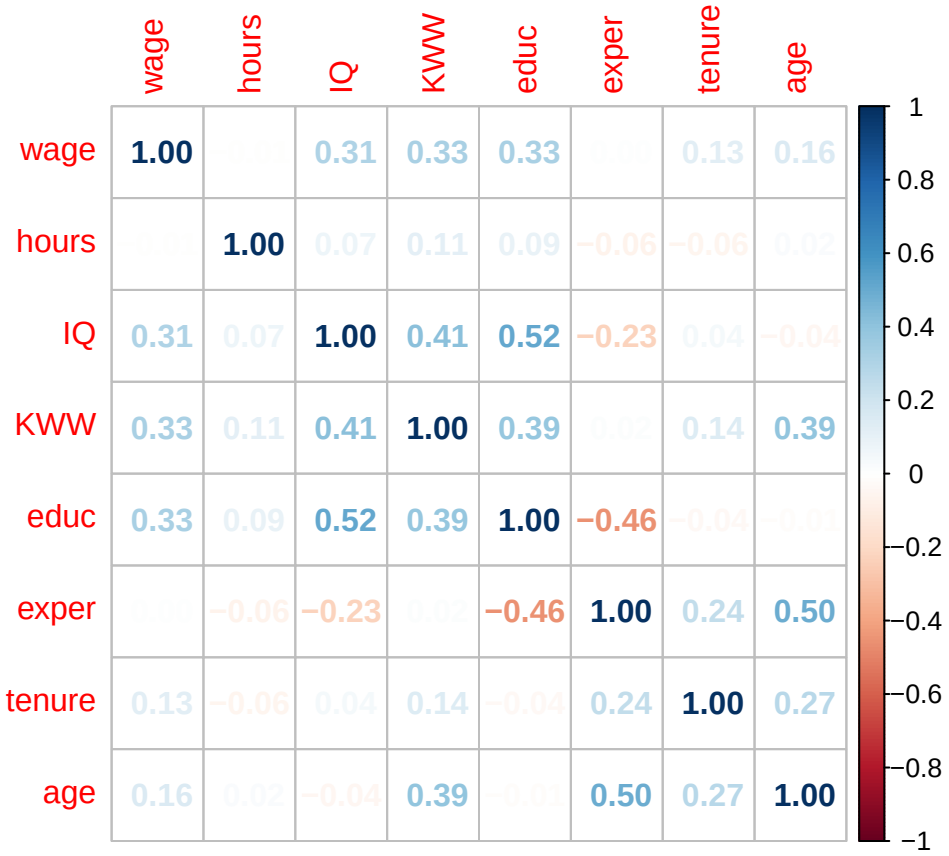
Nel complesso, quindi, si osserva che la maggior parte degli individui vive in area urbana, indipendentemente dallo stato civile. Tuttavia, la quota di residenti in città risulta leggermente più elevata tra i non sposati rispetto agli sposati.

```
##
##            0        1
##   0 69.00000 31.00000
##   1 65.46763 34.53237
```

La seconda tabella considera invece la relazione tra lo stato civile e la variabile `south`, che indica la residenza nel Sud. Tra gli individui non sposati, il 69% non vive nel Sud, mentre il 31% vive nel Sud. Tra gli individui sposati, invece, il 65,47% non vive nel Sud e il 34,53% vive nel Sud.

Anche in questo caso le differenze tra i due gruppi non appaiono particolarmente marcate. La maggioranza degli individui, sia sposati sia non sposati, non risiede nel Sud, anche se tra gli sposati si osserva una quota leggermente più alta di residenti nel Sud.

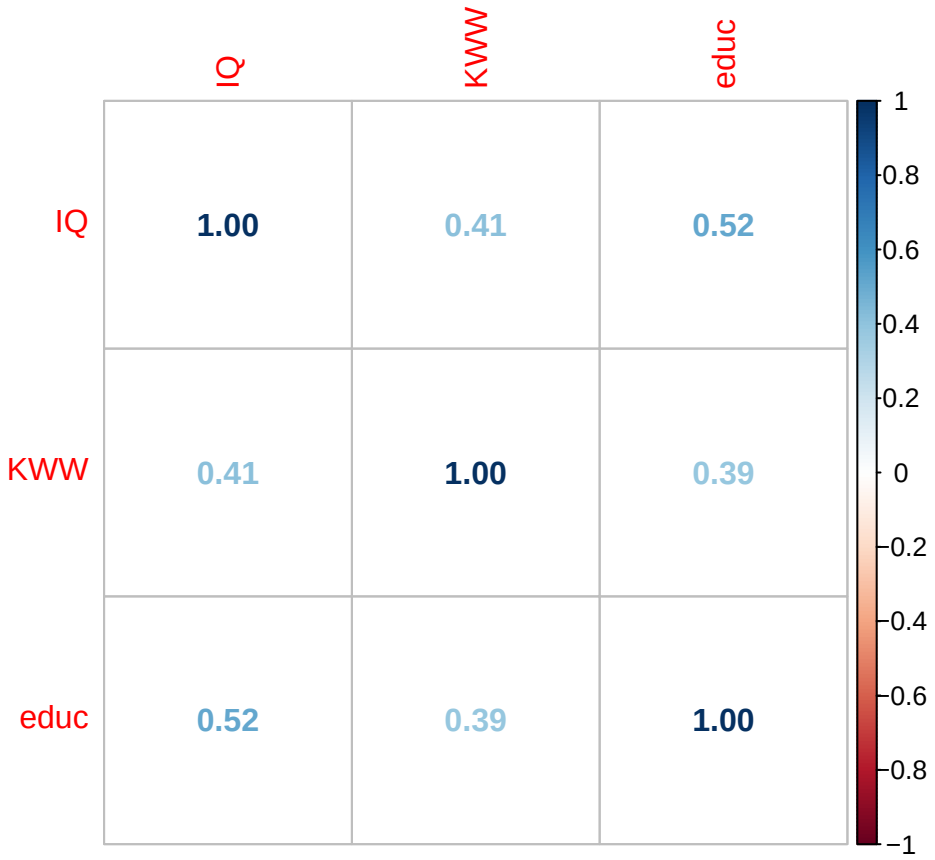
3.4 Analisi di correlazione



La matrice di correlazione consente di osservare le principali relazioni lineari tra le variabili numeriche del dataset. In generale, non emergono correlazioni estremamente elevate, ma alcune associazioni risultano comunque rilevanti.

La variabile `wage` presenta una correlazione positiva con `IQ`, `KWW` ed `educ`, suggerendo che il salario tende ad aumentare al crescere delle capacità cognitive, delle conoscenze legate al mondo del lavoro e degli anni di istruzione. Si osserva inoltre una correlazione positiva tra `exper` e `age`, coerente con il fatto che gli individui più anziani tendono ad avere più anni di esperienza lavorativa.

3.4.1 Correlazione tra le variabili relative al capitale umano



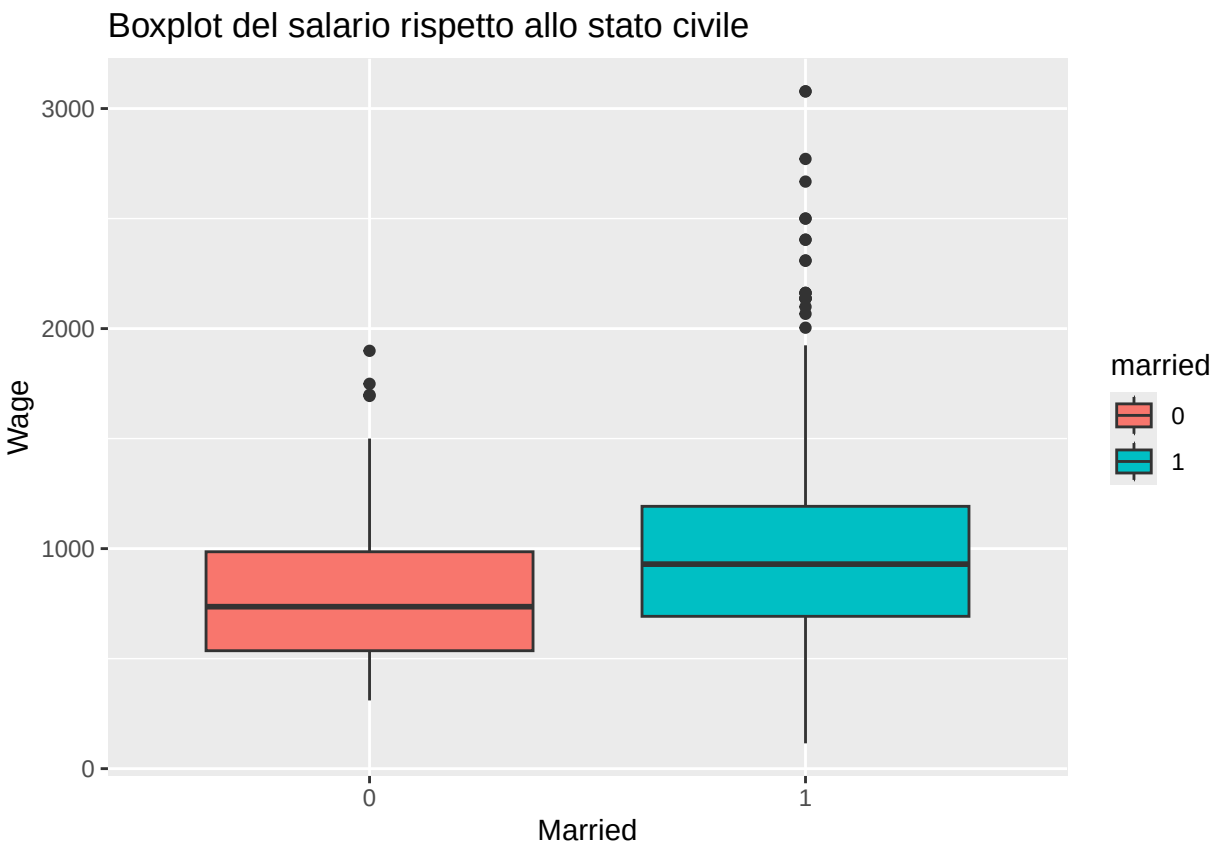
La seconda matrice si concentra sulle variabili `IQ`, `KWW` ed `educ`, che possono essere interpretate come indicatori di diverse dimensioni del capitale umano dell'individuo. La correlazione tra `IQ` ed `educ` è pari a circa 0.52, mentre quella tra `IQ` e `KWW` è pari a circa 0.41. Anche `KWW` ed `educ` risultano positivamente correlate, con un valore pari a circa 0.39.

Questi risultati sono coerenti con l'idea che capacità cognitive, conoscenze lavorative e livello di istruzione siano dimensioni distinte ma tra loro collegate. Tuttavia, le correlazioni non sono così elevate da suggerire una sovrapposizione completa tra le variabili; pertanto, nella fase di modellizzazione sarà possibile valutare se ciascuna di esse apporti un contributo informativo autonomo nella spiegazione del salario.

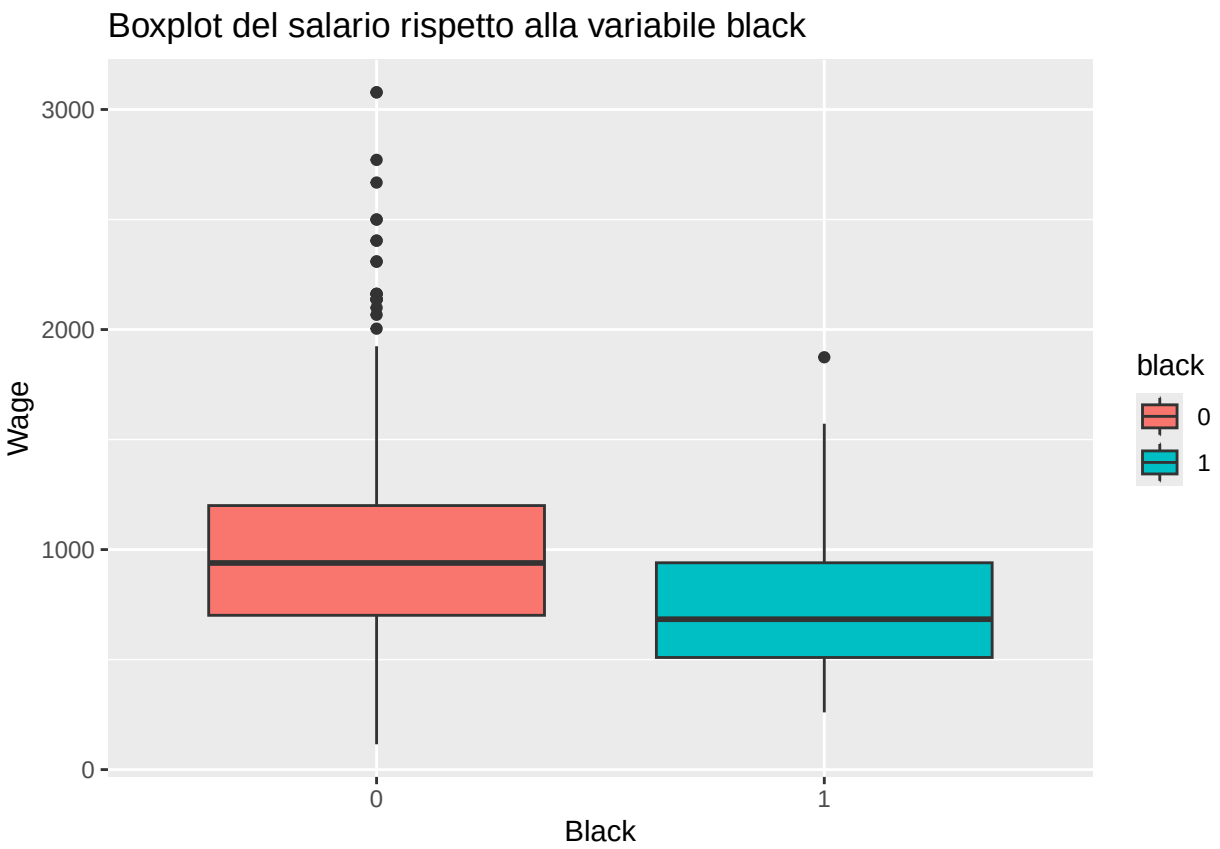
3.5 Grafici

3.5.1 Boxplot

Dopo aver osservato le statistiche descrittive e le relazioni tra alcune variabili qualitative, si analizza graficamente la distribuzione del salario rispetto ad alcune caratteristiche individuali. I boxplot consentono di confrontare la posizione centrale, la variabilità e la presenza di eventuali valori estremi nei diversi gruppi.



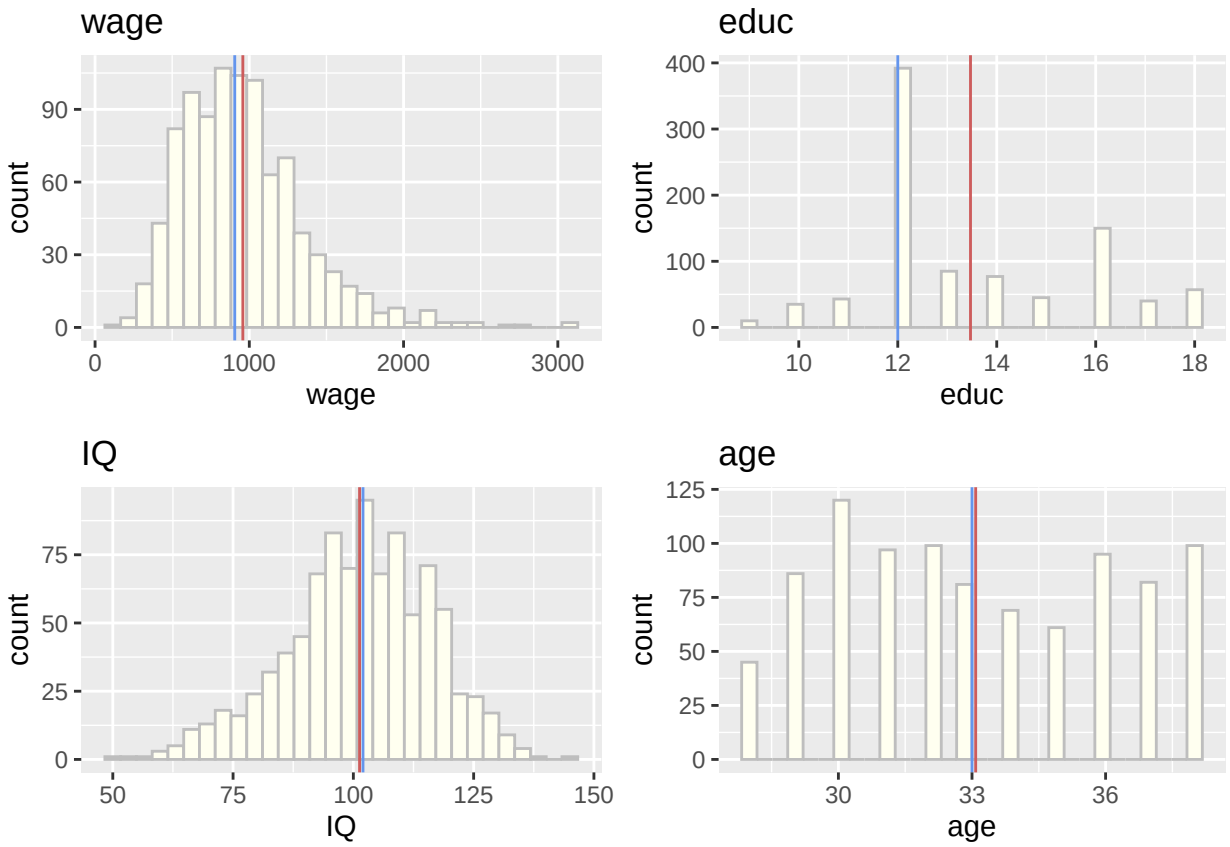
Dal grafico si osserva che gli individui sposati presentano una distribuzione salariale generalmente più elevata rispetto ai non sposati. In particolare, la mediana del salario appare più alta per il gruppo con `married = 1`. Inoltre, tra gli individui sposati si nota una maggiore presenza di valori salariali elevati, come evidenziato dagli outlier nella parte superiore del grafico.



Il secondo boxplot mostra una differenza nella distribuzione del salario rispetto alla variabile `black`. Gli individui bianchi presentano una mediana salariale più elevata e una maggiore dispersione verso valori alti del salario. Al contrario, per gli individui neri, la distribuzione appare concentrata su livelli salariali inferiori.

Queste differenze rappresentano evidenze descrittive osservate nel campione e non devono essere interpretate, in questa fase, come effetti causali. La successiva fase di modellizzazione consentirà di valutare se tali variabili mantengano un ruolo significativo anche controllando per altre caratteristiche individuali, come istruzione, esperienza, ore lavorate e capacità cognitive.

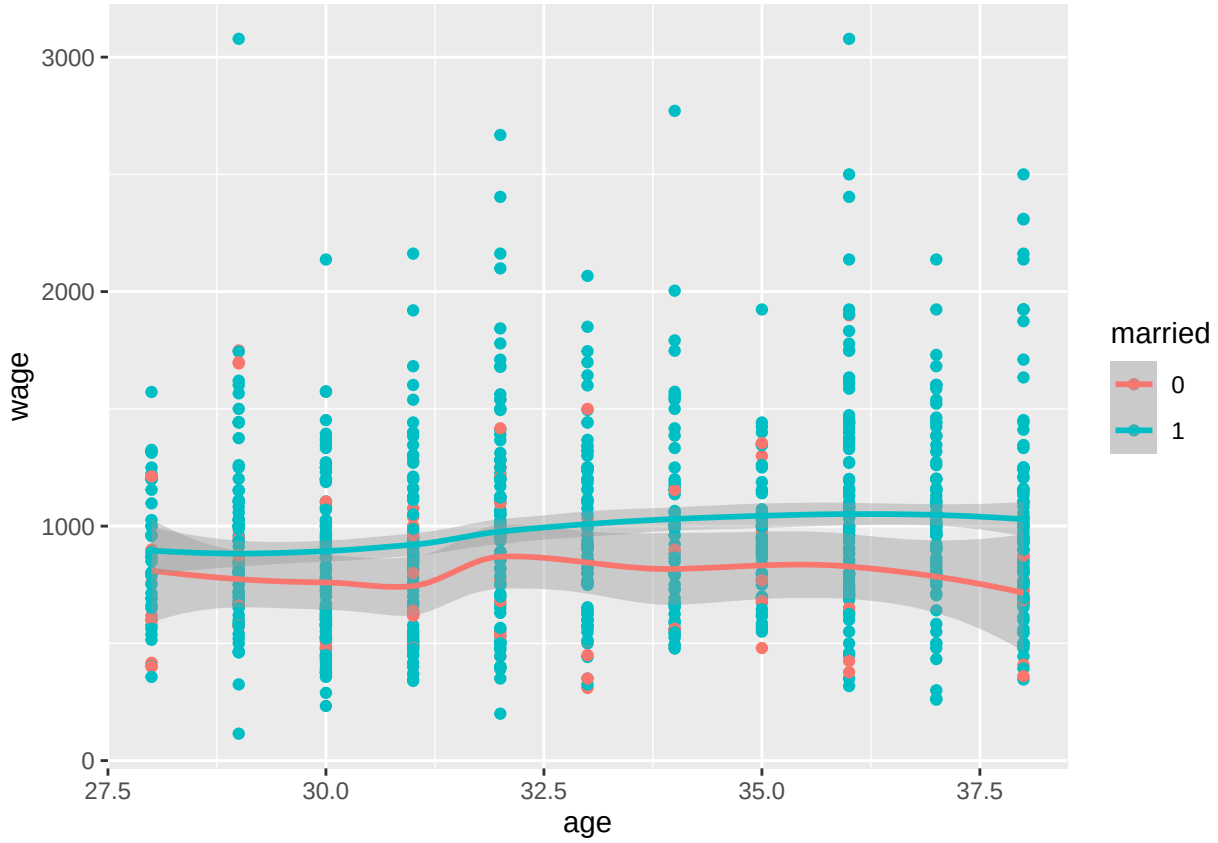
3.5.2 Istogrammi



Gli istogrammi consentono di osservare la distribuzione di alcune variabili principali del dataset. Le linee verticali rappresentano la media e la mediana, utili per valutare eventuali asimmetrie nella distribuzione.

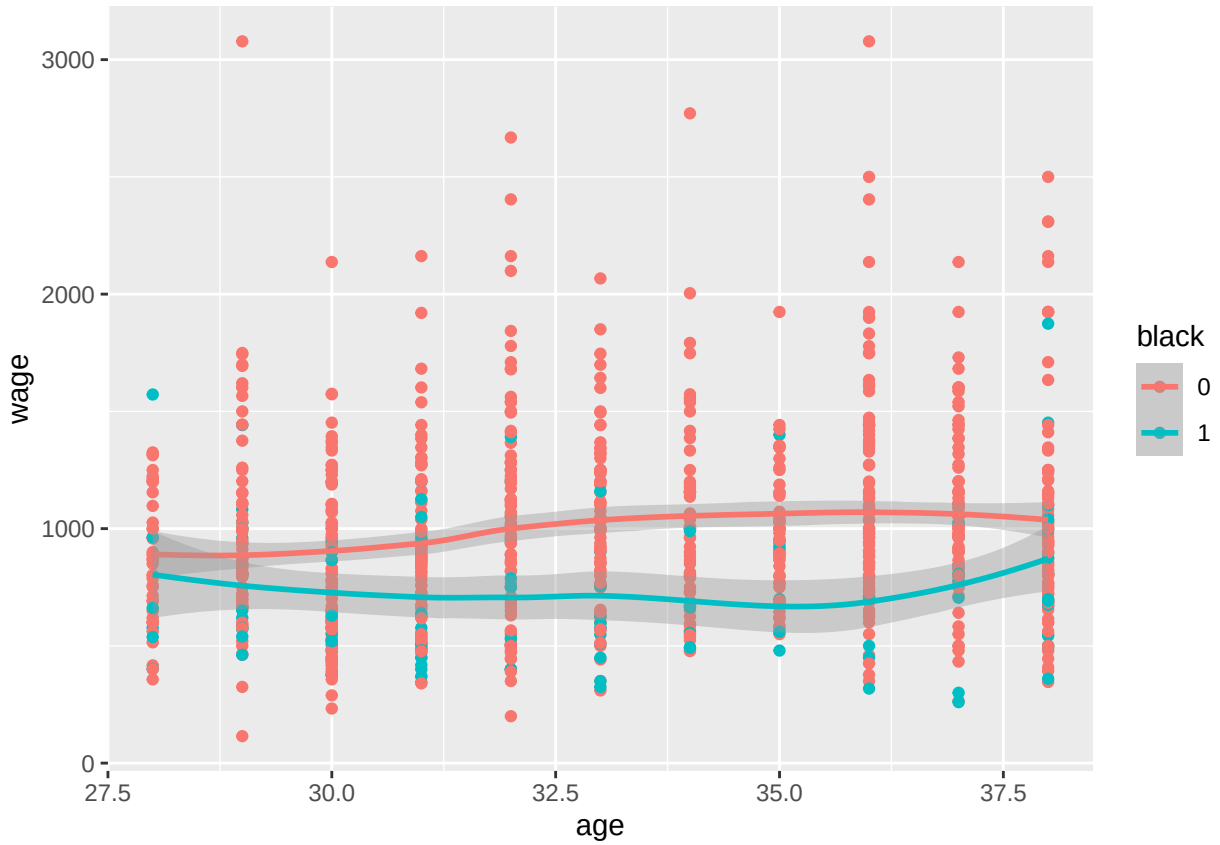
- `wage`: la distribuzione del salario mensile presenta una chiara asimmetria positiva, con una coda verso i valori più elevati. La media risulta superiore alla mediana, confermando la presenza di salari particolarmente alti rispetto alla maggior parte delle osservazioni. Questa caratteristica suggerisce che, nella fase di modellizzazione, possa essere opportuno considerare un modello adatto a variabili continue, positive e asimmetriche, come il GLM con distribuzione Gamma.
- `educ`: la variabile relativa agli anni di istruzione mostra una forte concentrazione intorno ai 12 anni, anche se sono presenti individui con livelli di istruzione più elevati.
- `IQ`: la distribuzione del punteggio IQ appare abbastanza regolare e centrata intorno a valori prossimi a 100. La vicinanza tra media e mediana suggerisce una distribuzione relativamente simmetrica.
- `age`: l'età degli individui è compresa in un intervallo piuttosto ristretto, tra circa 28 e 38 anni. Questo indica che il campione analizzato riguarda soggetti appartenenti a una fascia d'età abbastanza omogenea.

3.5.3 Scatterplot



Dal grafico si osserva che gli individui sposati presentano, nel campione, livelli salariali generalmente più elevati rispetto agli individui non sposati. Tale differenza appare abbastanza stabile lungo la fascia d'età osservata.

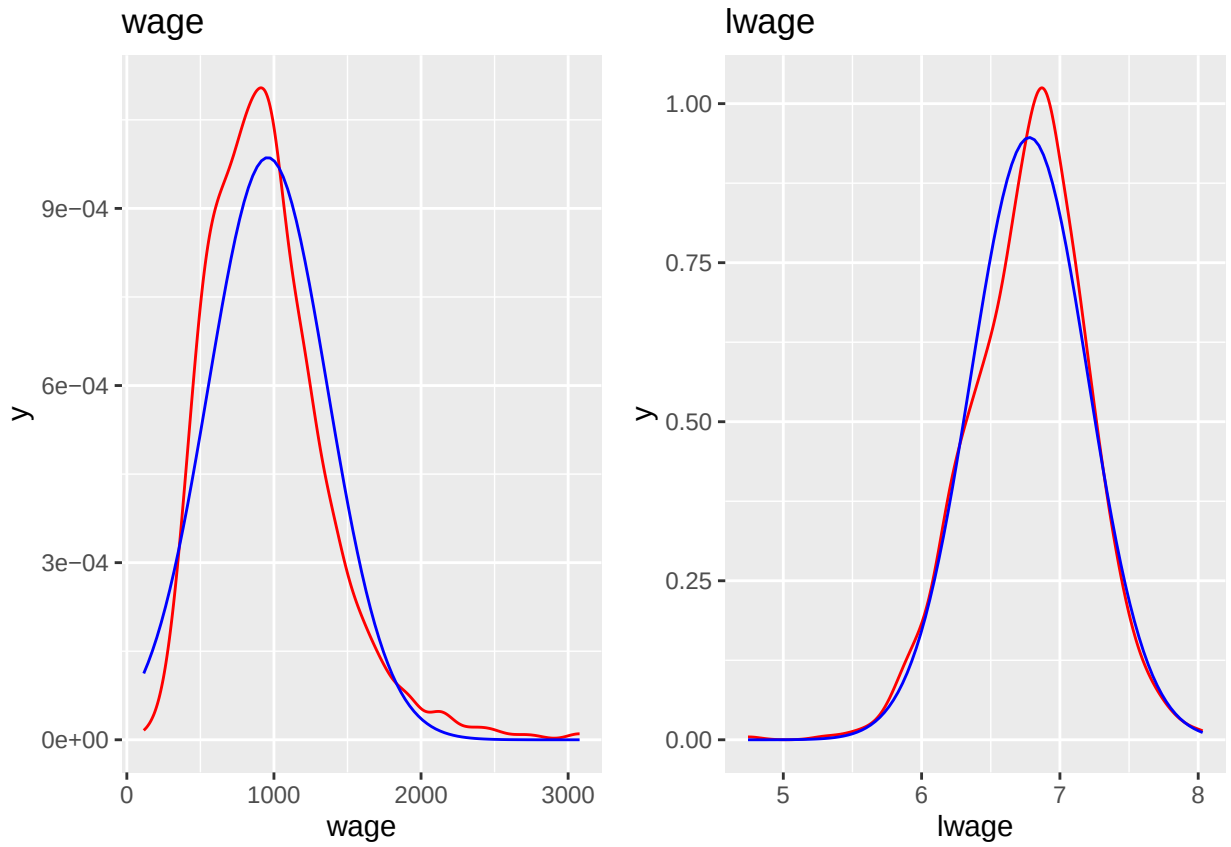
L'età, invece, non sembra mostrare una relazione lineare particolarmente marcata con il salario. Questa evidenza resta comunque descrittiva e dovrà essere verificata nella successiva fase di modellizzazione.



Dal grafico si osserva una differenza nella distribuzione del salario tra popolazione bianca e popolazione nera. In particolare, la popolazione bianca presenta, nel campione, livelli salariali generalmente più elevati rispetto alla popolazione nera lungo gran parte della fascia d'età osservata.

La popolazione nera risulta meno numerosa all'interno del campione e presenta una distribuzione salariale più concentrata su valori inferiori. Anche in questo caso, tuttavia, l'evidenza grafica deve essere interpretata con cautela: la differenza osservata è puramente descrittiva e non può essere considerata come un effetto causale. La successiva fase di modellizzazione permetterà di verificare se la variabile `black` risulti significativa anche controllando per altre caratteristiche individuali.

3.5.4 Density plot



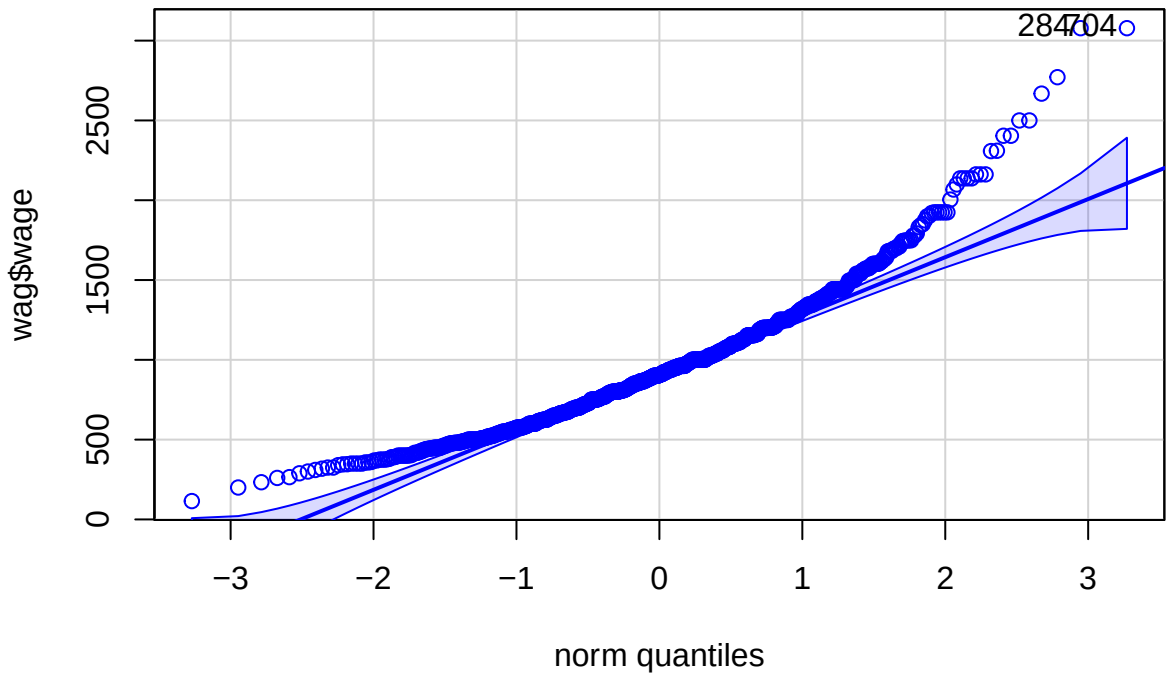
Il density plot consente di confrontare la distribuzione empirica delle variabili `wage` e `lwage` con una distribuzione normale avente stessa media e stessa deviazione standard. La curva rossa rappresenta la densità osservata, mentre la curva blu rappresenta la densità normale teorica.

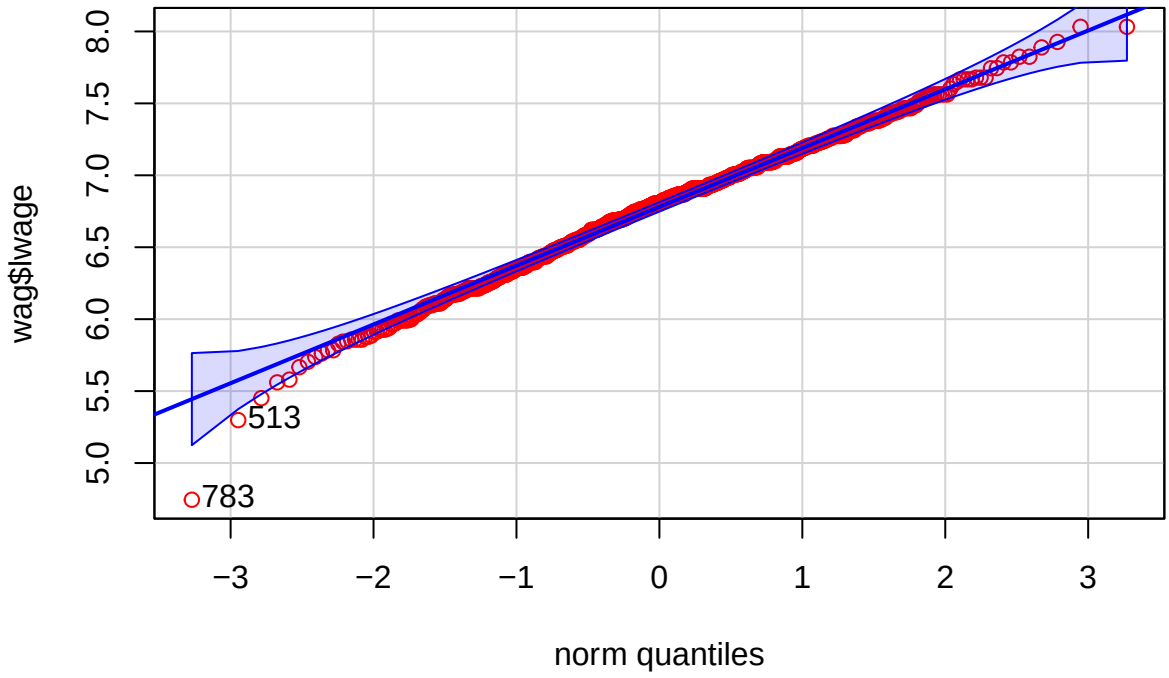
Per la variabile `wage` viene confermato quanto osservato in precedenza: la distribuzione presenta una chiara asimmetria positiva, con una coda verso i salari più elevati. Questo comportamento è tipico di molte variabili economiche positive, dove la maggior parte delle osservazioni si concentra su valori medio-bassi, mentre pochi individui presentano valori molto elevati.

La variabile `lwage`, cioè il logaritmo naturale del salario, presenta invece una distribuzione più simmetrica e più vicina alla normale. Questo risultato è coerente con l'effetto della trasformazione logaritmica, che tende a ridurre l'asimmetria positiva e a comprimere i valori estremamente elevati.

Questa evidenza sarà utile nella fase di modellizzazione, perché suggerisce due possibili strategie: modellare direttamente `wage` attraverso un GLM adatto a variabili positive e asimmetriche, oppure modellare `lwage` con un modello gaussiano, sfruttando la maggiore simmetria della variabile trasformata.

3.5.5 QQplot


wag$wage
0
500
1500
2500
−3
−2
−1
0
1
2
3
norm quantiles

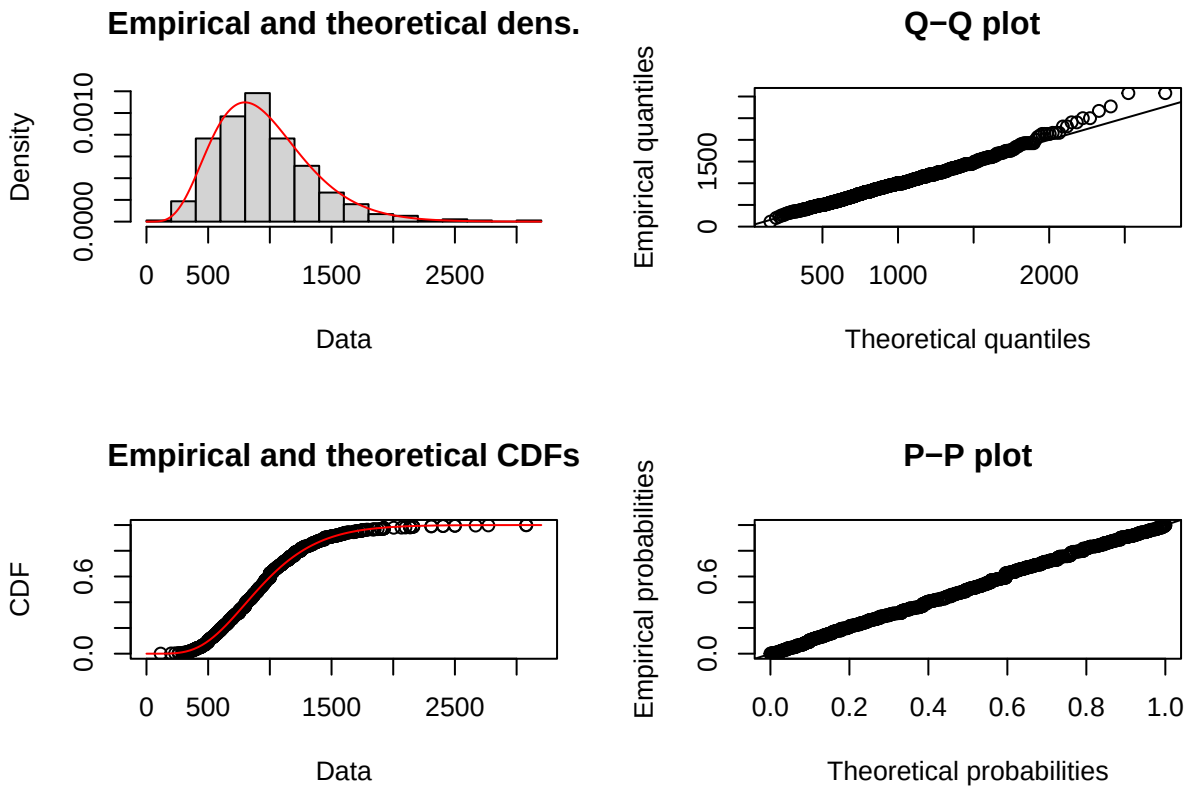

wag$lwage
5.0
5.5
6.0
6.5
7.0
7.5
8.0
513
783
−3
−2
−1
0
1
2
3
norm quantiles

Il QQplot consente di valutare graficamente la vicinanza delle variabili considerate a una distribuzione normale. Nel caso della variabile `wage`, i punti si discostano dalla retta teorica soprattutto nelle code, confermando che il salario mensile non presenta una distribuzione gaussiana.

Al contrario, la variabile `lwage` mostra un andamento più vicino alla retta di riferimento, suggerendo che la trasformazione logaritmica renda la distribuzione del salario più simmetrica e più prossima alla normalità.

3.6 Fit delle distribuzioni univariate

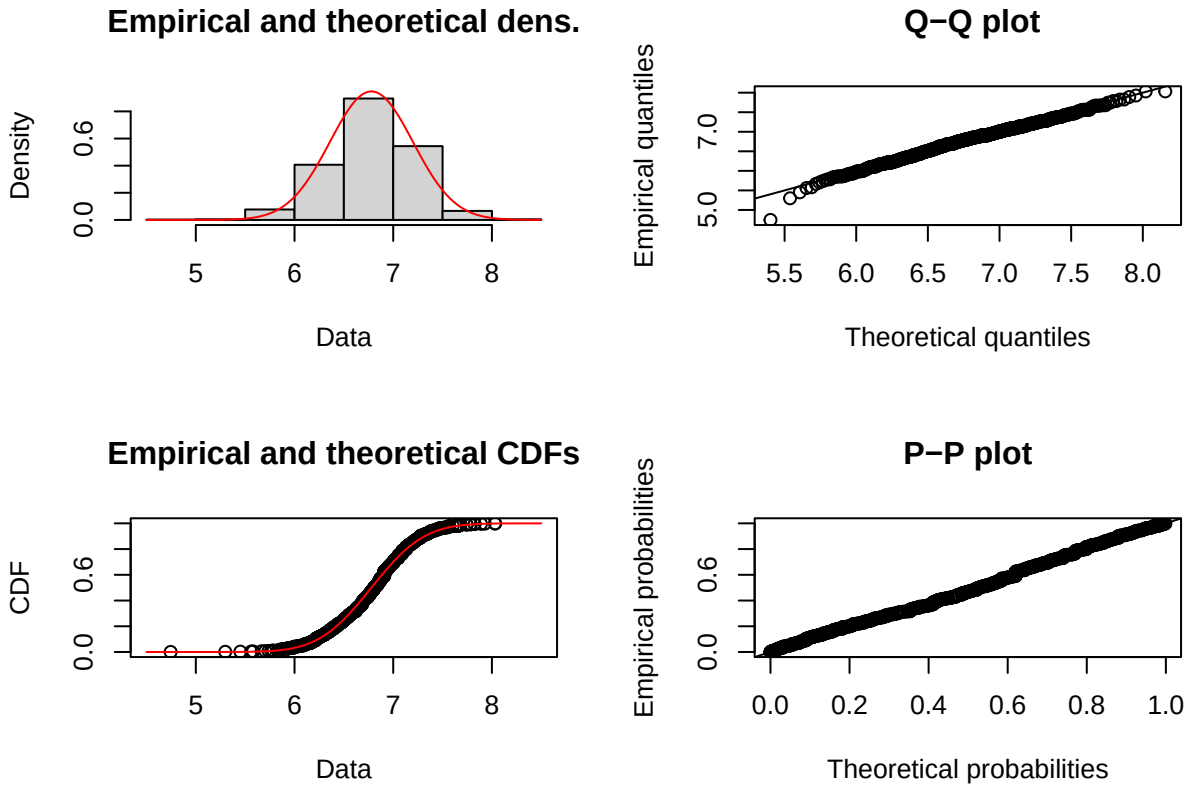
```
## Fitting of the distribution ' gamma ' by maximum likelihood
## Parameters :
##          estimate   Std. Error
## shape 5.986500466 0.2275497422
## rate  0.006248324 0.0002412017
## Loglikelihood:  -6847.35   AIC:  13698.7   BIC:  13708.38
## Correlation matrix:
##           shape      rate
## shape 1.0000000 0.9414037
## rate  0.9414037 1.0000000
```



Il fit della distribuzione Gamma sulla variabile `wage` conferma la possibilità di utilizzare una distribuzione asimmetrica per modellare direttamente il salario mensile. I grafici mostrano infatti che la distribuzione Gamma riesce a rappresentare la forma positiva e asimmetrica della variabile, pur con alcune differenze nelle code.

```
## Fitting of the distribution ' norm ' by maximum likelihood
## Parameters :
##       estimate  Std. Error
## mean 6.7791472 0.013779503
## sd   0.4211211 0.009743333
## Loglikelihood:  -517.5328   AIC:  1039.066   BIC:  1048.745
## Correlation matrix:
##      mean sd
```

```
## mean    1  0
## sd      0  1
```



Per il logaritmo del salario, invece, il confronto con la distribuzione normale risulta più appropriato. La variabile `lwage` appare infatti più simmetrica e più vicina alla forma gaussiana, come già osservato attraverso il density plot e il QQplot.

4 Costruzione del modello

Dopo l'analisi esplorativa, si procede con la costruzione dei modelli. L'obiettivo è confrontare un modello gaussiano applicato al logaritmo del salario con modelli più adatti alla variabile `wage`, che presenta valori positivi e distribuzione asimmetrica.

4.1 Suddivisione del dataset in training set e test set

Prima della fase di modellizzazione vengono eliminate le variabili `sibs`, `brthord`, `meduc` e `feduc`. Le variabili `brthord`, `meduc` e `feduc` presentano problemi legati alla presenza di valori mancanti o a un formato non numerico, mentre `sibs` viene esclusa per mantenere il modello più concentrato sulle variabili individuali, lavorative e formative maggiormente legate alla determinazione del salario.

Il dataset viene poi suddiviso in: training set, utilizzato per stimare i modelli, e test set, utilizzato per valutarne la capacità predittiva su osservazioni non impiegate nella fase di stima. In particolare, il 75% delle osservazioni viene assegnato al training set, mentre il restante 25% viene riservato al test set.

4.2 Regressione gaussiana con `lwage`

```
##
## Call:
## glm(formula = lwage ~ hours + IQ + KWW + educ + exper + tenure +
##     age + married + black + south + urban, data = wag_train)
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.337779   0.216808  24.620  < 2e-16 ***
## hours       -0.007363   0.001899  -3.878 0.000116 ***
## IQ           0.003157   0.001174   2.690 0.007313 **
## KWW          0.002903   0.002310   1.257 0.209265
## educ         0.049252   0.008610   5.721 1.58e-08 ***
## exper        0.011724   0.004397   2.666 0.007851 **
## tenure       0.010341   0.002895   3.572 0.000379 ***
## age          0.006774   0.005979   1.133 0.257612
## married1     0.180612   0.044323   4.075 5.14e-05 ***
## black1      -0.156346   0.045980  -3.400 0.000712 ***
## south1      -0.088844   0.030685  -2.895 0.003908 **
## urban1       0.194416   0.031540   6.164 1.21e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for gaussian family taken to be 0.1324525)
##
##     Null deviance: 129.161  on 699  degrees of freedom
## Residual deviance:  91.127  on 688  degrees of freedom
## AIC: 585.34
##
## Number of Fisher Scoring iterations: 2

##
## Call:
## glm(formula = lwage ~ hours + IQ + KWW + educ + exper + tenure +
```

```
##     married + black + south + urban, data = wag_train)
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.494005   0.167344  32.831  < 2e-16 ***
## hours       -0.007349   0.001899  -3.870 0.000119 ***
## IQ           0.002902   0.001152   2.519 0.011997 *
## KWW          0.003913   0.002132   1.836 0.066849 .
## educ         0.051012   0.008470   6.023 2.79e-09 ***
## exper        0.014061   0.003884   3.620 0.000316 ***
## tenure       0.010865   0.002859   3.801 0.000157 ***
## married1     0.183956   0.044233   4.159 3.60e-05 ***
## black1      -0.153785   0.045934  -3.348 0.000858 ***
## south1      -0.090788   0.030644  -2.963 0.003155 **
## urban1       0.194370   0.031546   6.161 1.23e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for gaussian family taken to be 0.132507)
##
##     Null deviance: 129.161  on 699  degrees of freedom
## Residual deviance:  91.297  on 689  degrees of freedom
## AIC: 584.64
##
## Number of Fisher Scoring iterations: 2
```

```
## Analysis of Deviance Table
##
## Model 1: lwage ~ hours + IQ + KWW + educ + exper + tenure + age + married +
##     black + south + urban
## Model 2: lwage ~ hours + IQ + KWW + educ + exper + tenure + married +
##     black + south + urban
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1       688     91.127
## 2       689     91.297 -1 -0.17003   0.2572
```

Il primo modello stimato considera come variabile risposta `lwage`, cioè il logaritmo naturale del salario. Questa scelta è motivata da quanto osservato nell'analisi esplorativa: rispetto alla variabile `wage`, il logaritmo del salario presenta una distribuzione più simmetrica e più vicina alla normale.

Vengono stimati due modelli gaussiani: un modello completo, che include anche la variabile `age`, e un modello ridotto, nel quale tale variabile viene esclusa. Il confronto tra i due modelli viene effettuato tramite test del rapporto di verosimiglianza.

Le ipotesi del test sono:

- H_0: il modello ridotto è sufficiente, quindi l'esclusione della variabile `age` non peggiora significativamente l'adattamento del modello;
- H_1: il modello completo offre un miglioramento significativo rispetto al modello ridotto.

Si considera un livello di significatività pari a $\alpha = 0{,}05$. Poiché il `p-value` del test è pari a circa 0,2572, maggiore di 0,05, non si rifiuta l'ipotesi nulla. Di conseguenza, i due modelli possono essere considerati equivalenti dal punto di vista statistico e, applicando il criterio di parsimonia, si sceglie il modello più semplice, cioè quello senza la variabile `age`.

```
##  (Intercept)        hours           IQ          KWW         educ        exper
##  5.494004635 -0.007349151  0.002901842  0.003912874  0.051012008  0.014061154
##       tenure     married1       black1       south1       urban1
##  0.010864628  0.183955827 -0.153785083 -0.090787601  0.194370461
```

```
##                     2.5 %       97.5 %
## (Intercept)  5.1660155448  5.821993724
## hours       -0.0110715800 -0.003626722
## IQ           0.0006439176  0.005159766
## KWW         -0.0002651287  0.008090876
## educ         0.0344109529  0.067613063
## exper        0.0064479854  0.021674322
## tenure       0.0052619998  0.016467256
## married1     0.0972598697  0.270651784
## black1      -0.2438133920 -0.063756774
## south1      -0.1508483008 -0.030726900
## urban1       0.1325411653  0.256199756
```

Il modello selezionato mostra che diverse variabili risultano statisticamente significative nella spiegazione del logaritmo del salario. In particolare, i coefficienti di `IQ`, `educ`, `exper`, `tenure`, `married` e `urban` sono positivi, indicando un'associazione positiva con il salario. Questo significa che, a parità delle altre variabili, valori più elevati di queste caratteristiche sono associati a livelli salariali più alti.

La variabile `KWW` presenta un coefficiente positivo, ma risulta solo debolmente significativa nel modello ridotto. Le variabili `black` e `south`, invece, presentano coefficienti negativi, suggerendo un'associazione con livelli salariali inferiori, sempre a parità delle altre caratteristiche incluse nel modello.

Il coefficiente della variabile `hours` risulta negativo e statisticamente significativo. Questo risultato deve essere interpretato con cautela, perché non implica necessariamente che lavorare più ore riduca il salario. Potrebbe infatti riflettere differenze nella tipologia di lavoro, nella retribuzione oraria o in altre caratteristiche non osservate.

Il modello log-lineare è utile soprattutto dal punto di vista interpretativo, perché consente di studiare l'associazione tra le variabili esplicative e il logaritmo del salario. Tuttavia, presenta una criticità nella fase previsiva sulla scala originaria del salario. Infatti, poiché il modello stima il logaritmo del salario, una semplice ritrasformazione esponenziale delle previsioni può introdurre distorsione.

Questo aspetto è collegato al fatto che, in generale:

$$E(Y \mid X) \neq \exp(E(\log(Y) \mid X)).$$

Pertanto, trasformare direttamente con l'esponenziale le previsioni ottenute per `lwage` non garantisce automaticamente previsioni non distorte del salario nella scala originale. Per questo motivo, ai fini previsivi, verranno considerati anche modelli GLM applicati direttamente alla variabile `wage`, come il modello Gamma, più adatto a variabili continue, positive e asimmetriche.

4.3 Regressione Gamma

```
##
## Call:
## glm(formula = wage ~ hours + IQ + KWW + educ + exper + tenure +
##     age + married + black + south + urban, family = Gamma(link = "log"),
##     data = wag_train)
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.339917   0.220626  24.203  < 2e-16 ***
## hours       -0.005376   0.001932  -2.782  0.00555 **
## IQ           0.003365   0.001194   2.818  0.00498 **
## KWW          0.004139   0.002351   1.761  0.07874 .
## educ         0.048232   0.008761   5.505 5.21e-08 ***
## exper        0.011811   0.004475   2.639  0.00849 **
## tenure       0.006936   0.002946   2.354  0.01883 *
## age          0.004933   0.006084   0.811  0.41776
## married1     0.176466   0.045103   3.912  0.00010 ***
## black1      -0.151855   0.046790  -3.245  0.00123 **
## south1      -0.076891   0.031226  -2.462  0.01404 *
## urban1       0.202359   0.032095   6.305 5.15e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Gamma family taken to be 0.1371587)
##
##     Null deviance: 124.845  on 699  degrees of freedom
## Residual deviance:  89.149  on 688  degrees of freedom
## AIC: 10086
##
## Number of Fisher Scoring iterations: 5
```

La regressione Gamma con link logaritmico viene utilizzata per modellare direttamente la variabile `wage`. Questa scelta è coerente con quanto osservato nell'analisi esplorativa, poiché il salario mensile è una variabile continua, positiva e caratterizzata da asimmetria positiva.

Nel modello completo sono incluse le variabili `hours`, `IQ`, `KWW`, `educ`, `exper`, `tenure`, `age`, `married`, `black`, `south` e `urban`. Dal riepilogo del modello si osserva che molte variabili risultano statisticamente significative. In particolare, `IQ`, `educ`, `exper`, `tenure`, `married` e `urban` presentano coefficienti positivi, mentre `hours`, `black` e `south` presentano coefficienti negativi. La variabile `age`, invece, non risulta statisticamente significativa.

Si confronta ora il modello completo con il modello contenente soltanto l'intercetta.

```
##
## Call:
## glm(formula = wage ~ 1, family = Gamma(link = "log"), data = wag_train)
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  6.87581    0.01628   422.5   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
```

```
## (Dispersion parameter for Gamma family taken to be 0.1854178)
##
##     Null deviance: 124.85  on 699  degrees of freedom
## Residual deviance: 124.85  on 699  degrees of freedom
## AIC: 10306
##
## Number of Fisher Scoring iterations: 4
```

```
## Analysis of Deviance Table
##
## Model 1: wage ~ 1
## Model 2: wage ~ hours + IQ + KWW + educ + exper + tenure + age + married +
##     black + south + urban
##   Resid. Df Resid. Dev Df Deviance  Pr(>Chi)
## 1       699    124.845
## 2       688     89.149 11   35.696 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Dal test del rapporto di verosimiglianza si osserva che il `p-value` è inferiore al livello di significatività fissato $\alpha = 0{,}05$. Pertanto, si rifiuta l'ipotesi nulla secondo cui il modello con sola intercetta è sufficiente. Il modello con le variabili esplicative presenta quindi una capacità informativa significativamente superiore rispetto al modello nullo.

Inoltre, la riduzione della devianza residua dal modello con sola intercetta al modello completo conferma che l'inclusione dei predittori migliora l'adattamento del modello ai dati.

Poiché nel modello completo la variabile `age` non risulta statisticamente significativa, si procede alla stima di un modello ridotto nel quale tale variabile viene esclusa.

```
##
## Call:
## glm(formula = wage ~ hours + IQ + KWW + educ + exper + tenure +
##     married + black + south + urban, family = Gamma(link = "log"),
##     data = wag_train)
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.452479   0.170184  32.039  < 2e-16 ***
## hours       -0.005337   0.001931  -2.763 0.005875 **
## IQ           0.003178   0.001172   2.713 0.006838 **
## KWW          0.004843   0.002168   2.234 0.025788 *
## educ         0.049630   0.008614   5.762 1.26e-08 ***
## exper        0.013511   0.003950   3.420 0.000662 ***
## tenure       0.007272   0.002907   2.502 0.012593 *
## married1     0.178953   0.044984   3.978 7.68e-05 ***
## black1      -0.150049   0.046713  -3.212 0.001379 **
## south1      -0.078789   0.031164  -2.528 0.011686 *
## urban1       0.202398   0.032081   6.309 5.03e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Gamma family taken to be 0.1370422)
##
```

```
##     Null deviance: 124.845  on 699  degrees of freedom
## Residual deviance:  89.239  on 689  degrees of freedom
## AIC: 10085
##
## Number of Fisher Scoring iterations: 5
```

Si confronta ora il modello completo con il modello ridotto senza la variabile `age`.

```
## Analysis of Deviance Table
##
## Model 1: wage ~ hours + IQ + KWW + educ + exper + tenure + married + black +
##     south + urban
## Model 2: wage ~ hours + IQ + KWW + educ + exper + tenure + age + married +
##     black + south + urban
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1       689     89.239
## 2       688     89.149  1 0.090253   0.4173
```

Il confronto tra il modello completo e il modello senza `age` consente di valutare se l'eliminazione di questa variabile peggiori significativamente l'adattamento del modello.

Le ipotesi del test sono:

- H_0: il modello ridotto, senza `age`, è sufficiente;
- H_1: il modello completo, con `age`, offre un miglioramento significativo.

Poiché il `p-value` risulta maggiore di 0,05, non si rifiuta H_0. L'eliminazione della variabile `age` non peggiora significativamente l'adattamento del modello. Pertanto, applicando il criterio di parsimonia, si sceglie il modello ridotto senza `age`.

Il modello Gamma selezionato è quindi:

$$E(wage \mid X) = \exp(\beta_0 + \beta_1 hours + \beta_2 IQ + \beta_3 KWW + \beta_4 educ + \beta_5 exper + \beta_6 tenure + \beta_7 married + \beta_8 black + \beta_9 south + \beta_{10} urban)$$

dove:

- *wage* rappresenta il salario mensile;
- β_0 rappresenta l'intercetta del modello;
- *hours*, *IQ*, *KWW*, *educ*, *exper*, *tenure*, *married*, *black*, *south* e *urban* rappresentano le variabili esplicative incluse nel modello;
- $\beta_1, \ldots, \beta_{10}$ rappresentano i coefficienti associati alle rispettive variabili esplicative.

4.3.1 Confronto tra modello Gamma con link logaritmico e modello Gamma con link inverso

```
##
## Call:
## glm(formula = wage ~ hours + IQ + KWW + educ + exper + tenure +
##     age + married + black + south + urban, family = Gamma(link = "inverse"),
##     data = wag_train)
##
## Coefficients:
```

```
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)  2.648e-03  2.275e-04  11.640  < 2e-16 ***
## hours        5.250e-06  2.085e-06   2.518  0.01203 *
## IQ          -3.545e-06  1.230e-06  -2.883  0.00406 **
## KWW         -5.580e-06  2.489e-06  -2.242  0.02528 *
## educ        -4.521e-05  8.647e-06  -5.229 2.27e-07 ***
## exper       -1.208e-05  4.593e-06  -2.631  0.00871 **
## tenure      -4.899e-06  2.943e-06  -1.664  0.09649 .
## age         -5.407e-06  6.343e-06  -0.852  0.39429
## married1    -1.880e-04  5.331e-05  -3.526  0.00045 ***
## black1       1.916e-04  5.930e-05   3.230  0.00130 **
## south1       7.741e-05  3.294e-05   2.350  0.01904 *
## urban1      -2.142e-04  3.640e-05  -5.886 6.18e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Gamma family taken to be 0.1376063)
##
##     Null deviance: 124.845  on 699  degrees of freedom
## Residual deviance:  89.537  on 688  degrees of freedom
## AIC: 10089
##
## Number of Fisher Scoring iterations: 5
```

Anche per il modello Gamma con link inverso viene inizialmente stimato un modello completo, contenente le stesse variabili esplicative utilizzate nel modello Gamma con link logaritmico. In questo modo è possibile confrontare le due specificazioni mantenendo invariata la struttura delle variabili incluse.

Poiché nel modello completo la variabile `age` non risulta statisticamente significativa, si procede anche in questo caso alla stima di un modello ridotto senza tale variabile.

```
##
## Call:
## glm(formula = wage ~ hours + IQ + KWW + educ + exper + tenure +
##     married + black + south + urban, family = Gamma(link = "inverse"),
##     data = wag_train)
##
## Coefficients:
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)  2.528e-03  1.782e-04  14.183  < 2e-16 ***
## hours        5.182e-06  2.083e-06   2.488 0.013082 *
## IQ          -3.346e-06  1.206e-06  -2.774 0.005693 **
## KWW         -6.434e-06  2.277e-06  -2.826 0.004844 **
## educ        -4.663e-05  8.491e-06  -5.491 5.62e-08 ***
## exper       -1.388e-05  4.106e-06  -3.382 0.000760 ***
## tenure      -5.361e-06  2.899e-06  -1.849 0.064817 .
## married1    -1.912e-04  5.314e-05  -3.599 0.000343 ***
## black1       1.887e-04  5.919e-05   3.187 0.001502 **
## south1       7.897e-05  3.288e-05   2.402 0.016560 *
## urban1      -2.132e-04  3.638e-05  -5.861 7.12e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Gamma family taken to be 0.1374755)
```

```
##
##     Null deviance: 124.845  on 699  degrees of freedom
## Residual deviance:  89.637  on 689  degrees of freedom
## AIC: 10088
##
## Number of Fisher Scoring iterations: 5
```

Per il confronto tra il modello Gamma con link logaritmico e il modello Gamma con link inverso si utilizzano i criteri AIC e BIC. Il confronto viene effettuato tra modelli stimati sulle stesse variabili esplicative, così da valutare esclusivamente l'effetto della diversa funzione di link.

```
## GAMMALOG1 GAMMAINV1
##  10084.83  10088.01
```

```
## GAMMALOG1 GAMMAINV1
##  10139.45  10142.63
```

Dai risultati ottenuti si osserva che il modello Gamma con link logaritmico presenta valori di AIC e BIC inferiori rispetto al modello Gamma con link inverso. In particolare, il modello `GAMMALOG1` mostra un AIC pari a 10084.83 e un BIC pari a 10139.45, mentre il modello `GAMMAINV1` presenta valori leggermente superiori.

Poiché valori più bassi di AIC e BIC indicano un miglior compromesso tra bontà di adattamento e complessità del modello, si sceglie di utilizzare il modello Gamma con link logaritmico. Tale modello consente inoltre una interpretazione più immediata dei coefficienti rispetto al link inverso, poiché gli effetti possono essere letti in termini moltiplicativi sulla media del salario.

4.3.2 Confronto tra modello Gamma e modello Inverse Gaussian

```
##
## Call:
## glm(formula = wage ~ hours + IQ + KWW + educ + exper + tenure +
##     age + married + black + south + urban, family = inverse.gaussian(link = "log"),
##     data = wag_train)
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.368748   0.221716  24.215  < 2e-16 ***
## hours       -0.005534   0.001873  -2.955 0.003231 **
## IQ           0.003504   0.001189   2.947 0.003316 **
## KWW          0.003063   0.002325   1.317 0.188154
## educ         0.047984   0.009078   5.286 1.68e-07 ***
## exper        0.011260   0.004500   2.502 0.012572 *
## tenure       0.008861   0.003017   2.937 0.003426 **
## age          0.004833   0.006085   0.794 0.427277
## married1     0.177066   0.042588   4.158 3.62e-05 ***
## black1      -0.153064   0.043281  -3.536 0.000433 ***
## south1      -0.080391   0.031086  -2.586 0.009913 **
## urban1       0.206131   0.031186   6.610 7.73e-11 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for inverse.gaussian family taken to be 0.0001521335)
##
```

```
##     Null deviance: 0.14787  on 699  degrees of freedom
## Residual deviance: 0.10909  on 688  degrees of freedom
## AIC: 10128
##
## Number of Fisher Scoring iterations: 7
```

Viene ora stimato un modello Inverse Gaussian con link logaritmico. Anche in questo caso si parte da un modello completo. Poiché la variabile `age` non risulta statisticamente significativa, si procede con un modello ridotto senza tale variabile.

```
##
## Call:
## glm(formula = wage ~ hours + IQ + KWW + educ + exper + tenure +
##     married + black + south + urban, family = inverse.gaussian(link = "log"),
##     data = wag_train)
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.479555   0.168938  32.435  < 2e-16 ***
## hours       -0.005510   0.001872  -2.944 0.003350 **
## IQ           0.003336   0.001168   2.855 0.004428 **
## KWW          0.003677   0.002157   1.704 0.088776 .
## educ         0.049486   0.008937   5.537 4.37e-08 ***
## exper        0.012988   0.003937   3.299 0.001020 **
## tenure       0.009109   0.002982   3.055 0.002339 **
## married1     0.178863   0.042508   4.208 2.92e-05 ***
## black1      -0.151579   0.043211  -3.508 0.000481 ***
## south1      -0.082651   0.030997  -2.666 0.007846 **
## urban1       0.206471   0.031156   6.627 6.91e-11 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for inverse.gaussian family taken to be 0.000151939)
##
##     Null deviance: 0.14787  on 699  degrees of freedom
## Residual deviance: 0.10919  on 689  degrees of freedom
## AIC: 10126
##
## Number of Fisher Scoring iterations: 7
```

Per confrontare il modello Gamma con link logaritmico e il modello Inverse Gaussian con link logaritmico si utilizzano i criteri AIC e BIC.

```
## GAMMALOG1  INVGAUS1
##  10084.83  10126.42
```

```
## GAMMALOG1  INVGAUS1
##  10139.45  10181.03
```

Dai risultati ottenuti si osserva che il modello Gamma con link logaritmico presenta valori di AIC e BIC inferiori rispetto al modello Inverse Gaussian con link logaritmico. Pertanto, secondo i criteri informativi, il modello Gamma con funzione di link logaritmica risulta preferibile.

4.4 Interpretazione dei coefficienti

```
##   (Intercept)         hours            IQ           KWW          educ
## 23233.5879963    -0.5322928     0.3183342     0.4855217     5.0882510
##         exper        tenure      married1        black1        south1
##     1.3603192     0.7298888    19.5965064   -13.9334587    -7.5765045
##        urban1
##    22.4335198
```

Poiché il modello Gamma utilizza una funzione di link logaritmica, i coefficienti possono essere interpretati in termini percentuali attraverso la trasformazione $(e^{\beta} - 1) \cdot 100$.

In particolare:

- un aumento di 1 ora lavorata settimanalmente determina una riduzione attesa del salario pari a circa lo 0,53%;
- un aumento di 1 punto nel punteggio `IQ` determina un incremento atteso del salario pari a circa lo 0,32%;
- un aumento di 1 punto nella conoscenza del mondo del lavoro, misurata dalla variabile `KWW`, determina un incremento atteso del salario pari a circa lo 0,49%;
- un anno aggiuntivo di istruzione determina un incremento atteso del salario pari a circa il 5,09%;
- un anno aggiuntivo di esperienza lavorativa determina un incremento atteso del salario pari a circa l'1,36%;
- un anno aggiuntivo presso l'attuale datore di lavoro, misurato dalla variabile `tenure`, determina un incremento atteso del salario pari a circa lo 0,73%;
- un individuo sposato presenta un salario atteso superiore di circa il 19,60% rispetto a un individuo non sposato;
- un individuo nero presenta un salario atteso inferiore di circa il 13,93% rispetto a un individuo bianco;
- un individuo che vive nel Sud presenta un salario atteso inferiore di circa il 7,58% rispetto a un individuo che non vive nel Sud;
- un individuo che vive in un'area urbana presenta un salario atteso superiore di circa il 22,43% rispetto a un individuo che vive in un'area non urbana.

È importante osservare che queste interpretazioni sono valide a parità delle altre variabili incluse nel modello. Inoltre, il coefficiente della variabile `hours` deve essere interpretato con cautela: il segno negativo non implica necessariamente che lavorare più ore riduca il salario, ma potrebbe riflettere differenze nella tipologia di occupazione, nella retribuzione oraria o in altre caratteristiche non osservate.

4.5 Previsioni

4.5.1 Hold-out Cross Validation: confronto tra modello Gamma e modello gaussiano

```
##    MAE.GAMMA MAE.GAUSSIAN
##     245.7324     243.2281

##    RMSE.GAMMA RMSE.GAUSSIAN
##      329.5387      331.0958
```

Nel confronto previsivo è necessario riportare le previsioni del modello gaussiano sulla scala originaria del salario. Per questo motivo, le previsioni ottenute sul logaritmo del salario vengono trasformate tramite funzione esponenziale.

I risultati ottenuti mostrano valori di errore molto vicini tra i due modelli. In particolare, il modello gaussiano applicato a `lwage` presenta un valore leggermente più basso del MAE, pari a circa 243.23, mentre il modello Gamma con link logaritmico presenta un valore leggermente più basso del RMSE, pari a circa 329.54.

Questa differenza suggerisce che non vi sia una superiorità netta di un modello sull'altro dal punto di vista predittivo. Tuttavia, il modello Gamma con link logaritmico rimane particolarmente adatto dal punto di vista teorico, poiché consente di modellare direttamente la variabile `wage`, che è continua, positiva e asimmetrica.

Il modello gaussiano su `lwage`, invece, risulta utile perché lavora su una variabile trasformata più vicina alla normalità, ma richiede una ritrasformazione esponenziale delle previsioni per tornare alla scala originaria del salario.

4.5.2 Previsioni su un nuovo data frame

```
##        1        2
## 848.0988 629.7960
```

Nel primo confronto, il modello prevede per il profilo con valori medi delle variabili quantitative un salario pari a circa 848.10. Il secondo profilo, invece, presenta valori inferiori per `IQ`, `KWW`, `educ` ed `exper`, mantenendo uguali le caratteristiche qualitative e lasciando `hours` e `tenure` al valore medio. In questo caso il salario previsto scende a circa 629.80. Il risultato è coerente con il segno positivo dei coefficienti associati alle variabili quantitative considerate.

```
##        1        2
## 848.0988 985.3990
```

Nel secondo confronto, a parità delle altre caratteristiche considerate, un individuo bianco presenta un salario previsto pari a circa 985.40, superiore rispetto al salario previsto per un individuo nero, pari a circa 848.10. Questo risultato è coerente con il coefficiente negativo della variabile `black`.

```
##        1        2
## 848.0988 823.9363
```

Nel terzo confronto, si osserva che un individuo bianco ma non sposato presenta un salario previsto pari a circa 823.94, inferiore rispetto a quello di un individuo nero ma sposato, pari a circa 848.10. Questo risultato mostra che l'effetto positivo associato alla variabile `married` può compensare, in questo specifico confronto, l'effetto negativo associato alla variabile `black`.

```
##        1        2
## 848.0988 917.6225
```

Nel quarto confronto, il profilo residente nel Sud presenta un salario previsto pari a circa 848.10, mentre il profilo non residente nel Sud presenta un salario previsto pari a circa 917.62. Questo conferma che, a parità delle altre caratteristiche considerate, vivere nel Sud è associato a un salario previsto inferiore.

```
##        1        2
## 848.0988 692.7015
```

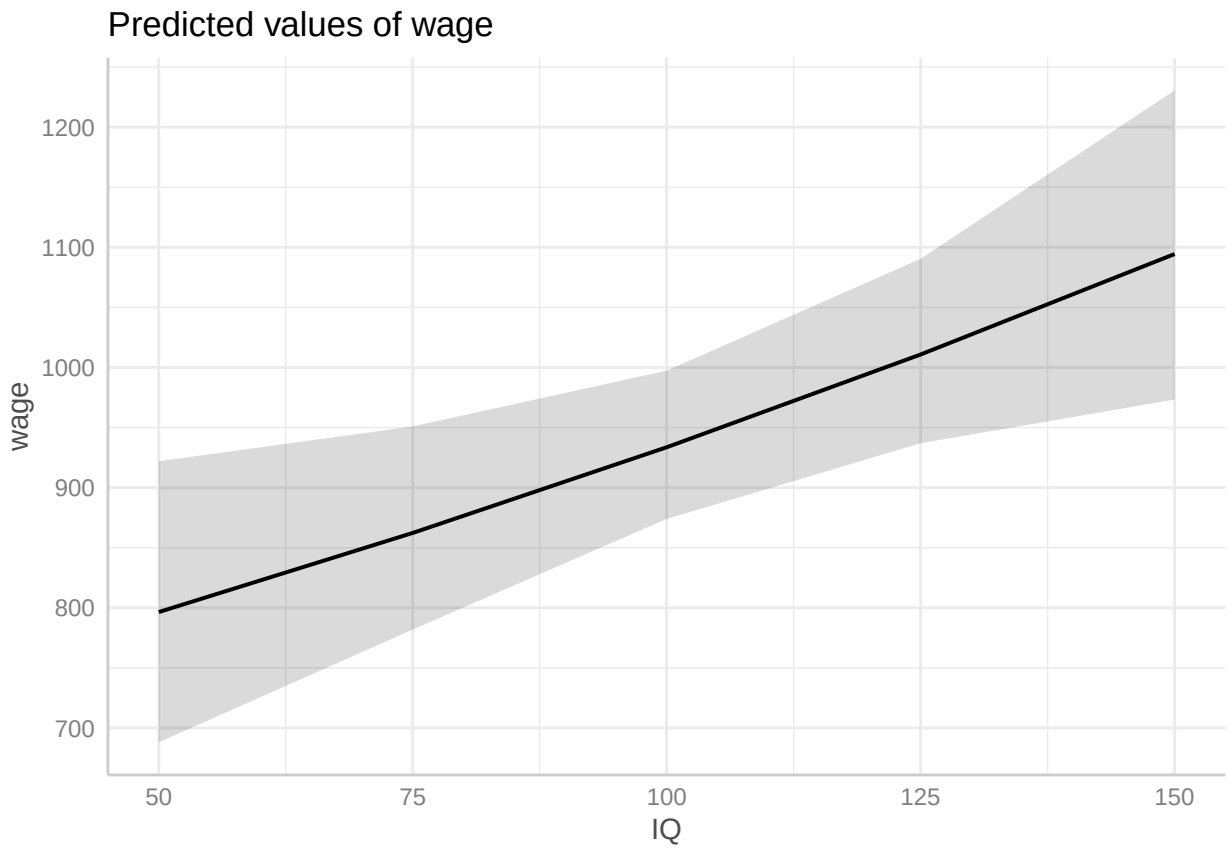
Nel quinto confronto, il profilo residente in area urbana presenta un salario previsto pari a circa 848.10, mentre il profilo residente in area non urbana presenta un salario previsto pari a circa 692.70. Il risultato conferma che vivere in città è associato a un salario previsto più elevato.

```
##         1         2
##  480.8086 1442.6085
```

Nell'ultimo confronto, si analizzano due individui entrambi sposati, neri, residenti nel Sud e in aree urbane, ma differenti rispetto alle variabili quantitative. Il primo profilo, con valori minimi di `hours`, `IQ`, `KWW`, `educ`, `exper` e `tenure`, presenta un salario previsto pari a circa 480.81. Il secondo profilo, con i rispettivi valori massimi, presenta invece un salario previsto pari a circa 1442.61. Il risultato evidenzia il ruolo complessivo delle variabili quantitative nella previsione del salario.

4.6 Effetti marginali

```
## # Predicted values of wage
##
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    796.43 | 688.01,  921.94
##  75 |    862.29 | 781.89,  950.97
## 100 |    933.61 | 873.95,  997.34
## 125 |   1010.81 | 936.97, 1090.47
## 150 |   1094.41 | 973.27, 1230.63
##
## Adjusted for:
## *  hours = 44.06
## *    KWW = 35.81
## *  exper = 11.50
## * tenure =  7.11
## *  black =     0
## *  south =     0
## *  urban =     0
```



Il primo grafico mostra l'andamento del salario previsto al variare del punteggio `IQ`, mantenendo fisso il livello di istruzione a 15 anni e considerando individui sposati. L'effetto stimato risulta crescente: a valori più elevati di `IQ` corrisponde un salario previsto maggiore.

L'area grigia rappresenta l'intervallo di confidenza della previsione. Si osserva che l'incertezza tende ad aumentare in corrispondenza dei valori più elevati di `IQ`, probabilmente perché tali valori sono meno frequenti

nel campione.

```
## # Predicted values of wage
##
## married: 0
## black: 0
##
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    618.81 | 527.38,  726.10
##  75 |    669.99 | 594.39,  755.21
## 100 |    725.40 | 657.28,  800.57
## 125 |    785.39 | 704.79,  875.20
## 150 |    850.34 | 737.32,  980.68
##
## married: 0
## black: 1
##
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    532.59 | 451.95,  627.63
##  75 |    576.64 | 503.62,  660.24
## 100 |    624.32 | 549.46,  709.38
## 125 |    675.95 | 584.94,  781.13
## 150 |    731.86 | 611.76,  875.52
##
## married: 1
## black: 0
##
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    740.08 | 645.44,  848.59
##  75 |    801.28 | 733.31,  875.56
## 100 |    867.55 | 816.95,  921.28
## 125 |    939.29 | 869.41, 1014.79
## 150 |   1016.97 | 899.90, 1149.28
##
## married: 1
## black: 1
##
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    636.96 | 550.64,  736.81
##  75 |    689.64 | 615.48,  772.72
## 100 |    746.67 | 671.40,  830.37
## 125 |    808.42 | 711.65,  918.34
## 150 |    875.27 | 740.78, 1034.18
##
## Adjusted for:
## *  hours = 44.06
## *    KWW = 35.81
## *   educ = 13.52
## *  exper = 11.50
## * tenure =  7.11
```

```
## *  south =     0
## *  urban =     0
```



Il secondo grafico consente di osservare l'effetto del punteggio `IQ` distinguendo gli individui sia per stato civile sia per popolazione bianca e popolazione nera. In entrambi i pannelli si conferma una relazione positiva tra `IQ` e salario previsto.

A parità di valore di `IQ`, gli individui sposati presentano un salario previsto più elevato rispetto agli individui non sposati. Inoltre, confrontando i due pannelli, si osserva che la popolazione bianca presenta livelli di salario previsto più elevati rispetto alla popolazione nera, coerentemente con il segno del coefficiente stimato per la variabile `black`.

```
## # Predicted values of wage
##
## married: 0
## educ: 9
##
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    494.43 | 420.96,  580.72
##  75 |    535.32 | 468.77,  611.32
## 100 |    579.59 | 510.75,  657.70
## 150 |    679.42 | 567.26,  813.75
##
## married: 0
## educ: 10
##
```

```
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    519.59 | 443.88,  608.20
##  75 |    562.56 | 495.93,  638.13
## 100 |    609.08 | 542.05,  684.39
## 150 |    713.99 | 602.47,  846.15
##
## married: 0
## educ: 11
##
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    546.03 | 467.22,  638.12
##  75 |    591.18 | 523.62,  667.46
## 100 |    640.07 | 574.26,  713.43
## 150 |    750.32 | 639.16,  880.80
##
## married: 0
## educ: 12
##
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    573.81 | 490.89,  670.74
##  75 |    621.26 | 551.62,  699.70
## 100 |    672.64 | 607.06,  745.31
## 150 |    788.49 | 677.22,  918.05
##
## married: 0
## educ: 13
##
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    603.00 | 514.81,  706.30
##  75 |    652.87 | 579.73,  735.24
## 100 |    706.86 | 640.09,  780.61
## 150 |    828.61 | 716.46,  958.33
##
## married: 0
## educ: 14
##
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    633.69 | 538.97,  745.06
##  75 |    686.09 | 607.83,  774.44
## 100 |    742.83 | 673.01,  819.90
## 150 |    870.78 | 756.66, 1002.10
##
## married: 0
## educ: 15
##
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    665.93 | 563.33,  787.22
##  75 |    721.00 | 635.85,  817.56
```

```
## 100 |    780.63 | 705.60,  863.64
## 150 |    915.08 | 797.59, 1049.88
##
## married: 0
## educ: 16
##
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    699.82 | 587.92,  833.00
##  75 |    757.69 | 663.82,  864.84
## 100 |    820.35 | 737.79,  912.15
## 150 |    961.64 | 839.02, 1102.19
##
## married: 0
## educ: 17
##
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    735.42 | 612.79,  882.60
##  75 |    796.24 | 691.81,  916.44
## 100 |    862.09 | 769.65,  965.63
## 150 |   1010.58 | 880.76, 1159.53
##
## married: 0
## educ: 18
##
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    772.84 | 637.97,  936.23
##  75 |    836.76 | 719.95,  972.52
## 100 |    905.96 | 801.37, 1024.20
## 150 |   1062.00 | 922.68, 1222.34
##
## married: 1
## educ: 9
##
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    591.32 | 516.62,  676.83
##  75 |    640.22 | 578.29,  708.79
## 100 |    693.17 | 630.17,  762.46
## 150 |    812.56 | 690.76,  955.84
##
## married: 1
## educ: 10
##
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    621.41 | 544.74,  708.87
##  75 |    672.80 | 612.57,  738.94
## 100 |    728.44 | 670.53,  791.35
## 150 |    853.90 | 734.13,  993.22
##
## married: 1
```

```
## educ: 11
##
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    653.03 | 573.18,  744.00
##  75 |    707.03 | 647.24,  772.35
## 100 |    765.50 | 712.16,  822.84
## 150 |    897.35 | 779.34, 1033.23
##
## married: 1
## educ: 12
##
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    686.25 | 601.78,  782.58
##  75 |    743.01 | 681.79,  809.72
## 100 |    804.45 | 754.29,  857.95
## 150 |    943.01 | 826.18, 1076.36
##
## married: 1
## educ: 13
##
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    721.17 | 630.47,  824.93
##  75 |    780.81 | 715.83,  851.69
## 100 |    845.39 | 795.86,  898.00
## 150 |    990.99 | 874.36, 1123.18
##
## married: 1
## educ: 14
##
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    757.87 | 659.20,  871.31
##  75 |    820.54 | 749.18,  898.71
## 100 |    888.40 | 835.86,  944.25
## 150 |   1041.42 | 923.53, 1174.36
##
## married: 1
## educ: 15
##
##  IQ | Predicted |          95% CI
## --------------------------------
##  50 |    796.43 | 688.01,  921.94
##  75 |    862.29 | 781.89,  950.97
## 100 |    933.61 | 873.95,  997.34
## 150 |   1094.41 | 973.27, 1230.63
##
## married: 1
## educ: 16
##
##  IQ | Predicted |           95% CI
## ---------------------------------
```

```
##  50 |    836.95 |  716.96,  977.03
##  75 |    906.17 |  814.20, 1008.53
## 100 |    981.11 |  910.51, 1057.18
## 150 |   1150.09 | 1023.22, 1292.69
##
## married: 1
## educ: 17
##
##  IQ | Predicted |           95% CI
## ----------------------------------
##  50 |    879.54 |  746.15, 1036.78
##  75 |    952.28 |  846.37, 1071.44
## 100 |   1031.03 |  946.24, 1123.42
## 150 |   1208.61 | 1073.14, 1361.19
##
## married: 1
## educ: 18
##
##  IQ | Predicted |           95% CI
## ----------------------------------
##  50 |    924.29 |  775.68, 1101.38
##  75 |   1000.73 |  878.68, 1139.74
## 100 |   1083.49 |  981.75, 1195.78
## 150 |   1270.11 | 1122.89, 1436.64
##
## Adjusted for:
## *  hours = 44.06
## *    KWW = 35.81
## *  exper = 11.50
## * tenure =  7.11
## *  black =     0
## *  south =     0
## *  urban =     0
```



L'ultimo grafico mostra come il salario previsto cambi al variare di `IQ`, distinguendo anche per stato civile e livello di istruzione. In tutti i pannelli si osserva un andamento crescente del salario previsto rispetto a `IQ`.

Al crescere degli anni di istruzione, il livello del salario previsto aumenta progressivamente. Inoltre, all'interno di ciascun livello di istruzione, gli individui sposati presentano valori previsti più elevati rispetto agli individui non sposati. Il risultato conferma quindi il ruolo positivo delle variabili legate al capitale umano, in particolare `IQ` ed `educ`, nella spiegazione del salario.

5 Conclusioni

Il dataset consente di analizzare il salario mensile considerando diverse variabili relative alle caratteristiche individuali, formative e lavorative degli individui osservati. L'analisi esplorativa ha mostrato che la variabile `wage` presenta valori positivi e una distribuzione asimmetrica a destra, mentre la variabile `lwage`, cioè il logaritmo naturale del salario, risulta più vicina a una distribuzione normale.

In primo luogo, la variabile `married` risulta associata a un salario previsto più elevato. Questo risultato emerge sia dall'analisi grafica sia dalla stima del modello Gamma finale. Tuttavia, tale evidenza deve essere interpretata come associazione statistica e non come effetto causale diretto, poiché il risultato potrebbe dipendere anche da caratteristiche socio-economiche non incluse nel modello.

La variabile `black` risulta associata a un salario inferiore rispetto alla categoria di riferimento. Di conseguenza, a parità delle altre caratteristiche considerate, gli individui bianchi tendono a presentare un salario previsto più elevato rispetto agli individui neri. Anche in questo caso, l'interpretazione deve rimanere prudente, poiché il modello misura un'associazione condizionata alle variabili disponibili e non consente di stabilire un rapporto causale.

Le variabili legate al capitale umano, come `IQ`, `KWW`, `educ` ed `exper`, mostrano un ruolo rilevante nella spiegazione del salario. In particolare, anni di istruzione, conoscenza del mondo del lavoro ed esperienza lavorativa contribuiscono positivamente alla previsione del salario. Anche la variabile `tenure`, che misura gli anni trascorsi presso l'attuale datore di lavoro, viene mantenuta nel modello finale e presenta un'associazione positiva con il salario previsto.

La variabile `age`, invece, non viene mantenuta nel modello Gamma finale, poiché non risulta statisticamente significativa e la sua esclusione non peggiora in modo rilevante l'adattamento del modello. Per questo motivo, applicando il criterio di parsimonia, si sceglie una specificazione più semplice senza tale variabile.

Dal confronto tra le diverse specificazioni considerate, il modello Gamma con funzione di link logaritmica risulta preferibile rispetto al modello Gamma con link inverso e al modello Inverse Gaussian, poiché presenta valori più bassi di AIC e BIC. Inoltre, tale modello consente di lavorare direttamente sulla variabile `wage`, rispettando la natura positiva e asimmetrica del salario.

Dal punto di vista previsivo, il confronto tra modello Gamma e modello gaussiano applicato a `lwage` mostra risultati molto simili. Il modello gaussiano presenta un valore leggermente più basso del MAE, mentre il modello Gamma presenta un valore leggermente più basso del RMSE. Pertanto, non emerge una superiorità netta di un modello sull'altro in termini predittivi. Tuttavia, il modello Gamma con link logaritmico risulta preferibile dal punto di vista della specificazione, poiché permette di modellare direttamente il salario nella sua scala originaria, senza dover ricorrere alla ritrasformazione esponenziale delle previsioni.

In conclusione, l'analisi conferma che il salario è influenzato da una combinazione di caratteristiche individuali, formative, lavorative e territoriali. Il modello Gamma con link logaritmico rappresenta una scelta adeguata per descrivere e prevedere il salario mensile, pur mantenendo cautela nell'interpretazione dei risultati, che devono essere letti come associazioni statistiche e non come relazioni causali.